SOLO RAG DEMO CF

เดโม RAG บน Cloudflare Workers (ถูกแทนที่แล้ว) เก็บข้อมูลในหน่วยความจำ

Product Card

รหัสเอกสาร	CARD-solo-rag-demo-cf
ฉบับ	0.1
วันที่	2026-10-11
สถานะ	ร่างเพื่อพิจารณา

เอกสารภายในฉบับร่าง — ใช้ประกอบการพัฒนาและดูแลระบบ

สารบัญ

1. สรุปคุณค่าในหนึ่งประโยค
2. ปัญหาและผู้ใช้เป้าหมาย
3. สิ่งที่ทำได้จริงตอนนี้
4. หลักฐานสถานะ
5. คุณค่าและจุดต่าง
6. ช่องว่างสำคัญ
7. คำตัดสิน
8. ขั้นต่อไป
การอนุมัติ
แหล่งข้อมูล

solo-rag-demo-cf — Product Card

1. สรุปคุณค่าในหนึ่งประโยค

เดโมที่แสดงว่าอัปโหลดเอกสาร แล้วถามตอบภาษาไทยพร้อมอ้างอิงแหล่งได้ บน Cloudflare Workers AI

2. ปัญหาและผู้ใช้เป้าหมาย

- ปัญหา: องค์กรอยากให้เอกสารตอบคำถามได้ตลอดเวลา — เป็นข้อเสนอเดโม ยังไม่มีลูกค้ายืนยัน
- ผู้ใช้เป้าหมาย: ธุรกิจไทยขนาดเล็ก **[สมมติฐาน]**

3. สิ่งที่ทำได้จริงตอนนี้

- Worker รับ `POST /upload`, `POST /query`, `GET /stats` และมี embeddings (`@cf/baai/bge-base-en-v1.5`) กับ LLM `@cf/meta/llama-3-8b-instruct` ตาม README
- เก็บข้อมูลใน memory แบบสาธารณะ; README ระบุว่าเป็น demo ที่ superseded และห้ามใช้กับข้อมูลจริง
- `npm run deploy` ถูกบล็อกด้วย predeploy guard ต้องตั้ง `ALLOW_RAG_DEMO_DEPLOY=true` จึงจะ deploy

4. หลักฐานสถานะ

รายการ	ค่า (ตรวจจาก repository)
Stack	JavaScript (Cloudflare Workers)
Commits	12 (แรก 2026-07-04 → ล่าสุด 2026-10-11)
Source	ประมาณ 662 บรรทัดใน 2 ไฟล์ (ไม่รวมเทสต์)
Tests	ไม่มี
CI	ไม่มี
Deploy config	`wrangler.toml` (Cloudflare Workers) พร้อม predeploy guard; ไม่มี live URL ที่ตรวจได้
Live URL	ไม่มี (ไม่ได้ตรวจ)
README	143 บรรทัด

5. คุณค่าและจุดต่าง

- จุดต่างเดียวคือเดโม Thai + citation บน edge ราคาถูก
- มุมรายได้: ซ้ำกับ `ai-doc-assistant` (FastAPI, ชื่อ README เดียวกัน) **[ต้องยืนยัน]** ว่าตัวไหนเป็น canonical

6. ช่องว่างสำคัญ

- README บอกเองว่า superseded
- ไม่มีที่เก็บถาวร ไม่มี auth ไม่มีเทสต์ ไม่มี CI

- README พิมพ์ชื่อโมเดลว่า Llama 3.8B ทั้งที่ใช้ llama-3-8b-instruct — ควรแก้

7. คำตัดสิน

`merge` — ซ้ำหัวข้อกับ `ai-doc-assistant` และถูกระบุว่า superseded; canonical twin: `ai-doc-assistant` (ต้องให้เจ้าของยืนยัน) จะเปลี่ยนถ้ามีลูกค้าที่ต้องการ edition บน Cloudflare โดยเฉพาะ

8. ขั้นต่อไป

1. ยืนยัน canonical twin กับเจ้าของ แล้วเก็บเฉพาะส่วนที่ต่างไว้ใน `ai-doc-assistant`
2. ถ้าไม่ใช้ต่อ ให้เสนอ archive

การอนุมัติ

บทบาท	สถานะ	วันที่	ลงนาม
Product owner (Book Dev)	รอพิจารณา	—	_

แหล่งข้อมูล

- `README.md`
- `wrangler.toml`, `src/`, `scripts/`